Fundamentos del aprendizaje profundo 2

Juan Pajaro

8 abril 2026

Aprendizaje de máquina vs profundo

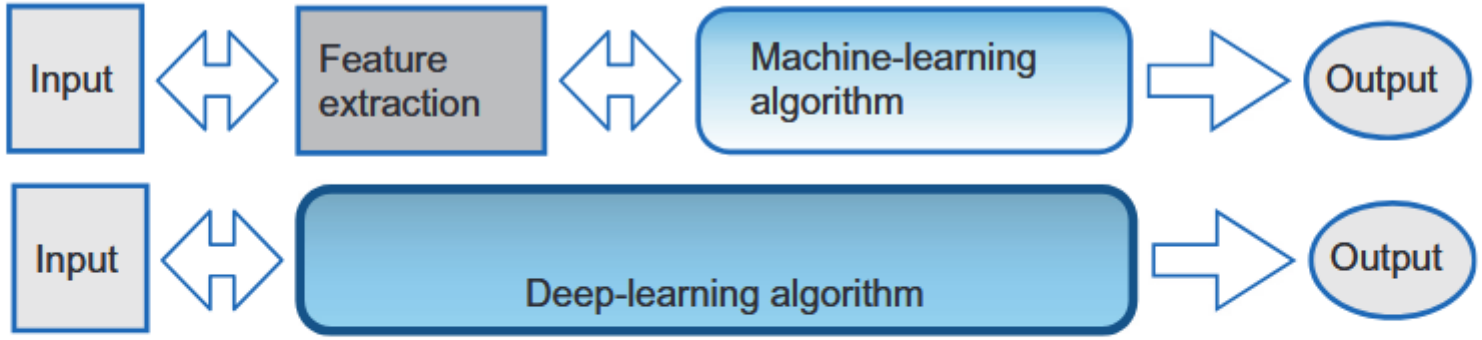

FIGURE 5.32 Machine versus deep learning. The workflow for both machine and deep learning are depicted. In machine learning, feature extraction is manually done followed by the use of the algorithm with a shallow structure. In deep learning, there is no separate feature extraction as it is inclusive of the deep learning end-to-end algorithm (which creates a "black box" perception).

Aprendizaje de máquina vs profundo

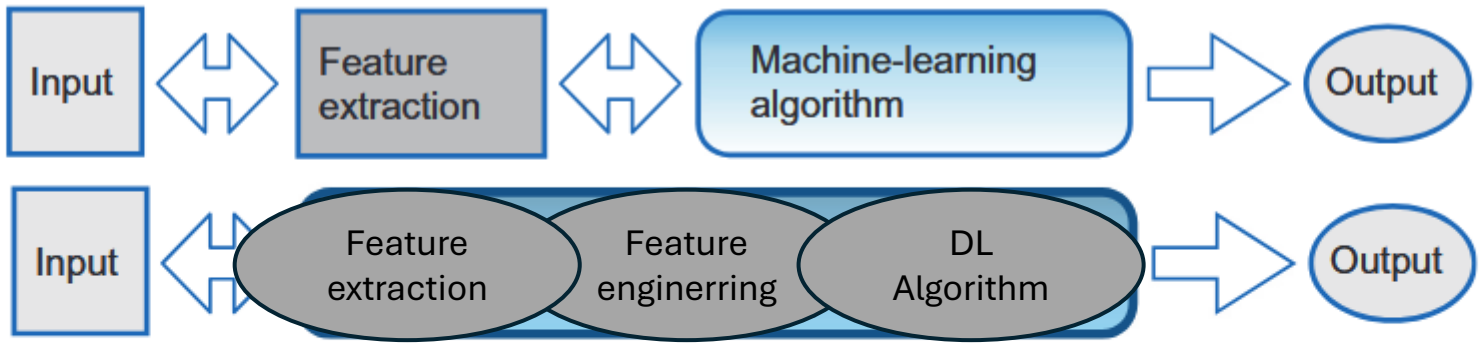

FIGURE 5.32 Machine versus deep learning. The workflow for both machine and deep learning are depicted. In machine learning, feature extraction is manually done followed by the use of the algorithm with a shallow structure. In deep learning, there is no separate feature extraction as it is inclusive of the deep learning end-to-end algorithm (which creates a "black box" perception).

Aprendizaje de máquina vs profundo

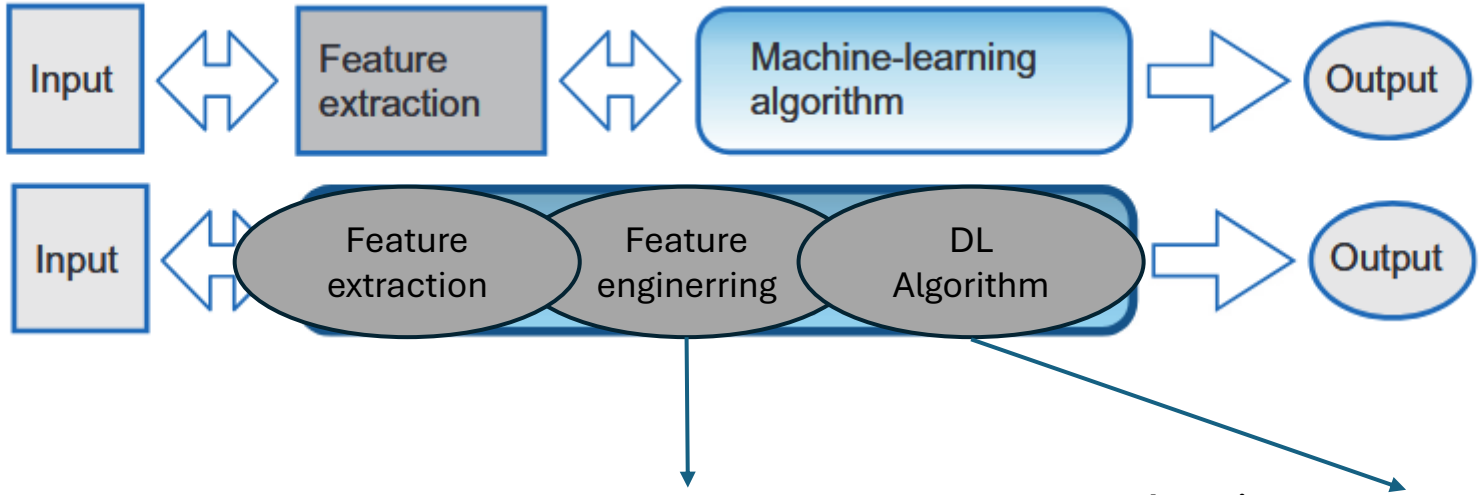

Para texto:

- One-hot encoding
- TF-IDF
- Embedding

Arquitectura:

- Densas
- Recurrentes
- Convolucionales
- Transformers

La generalización es lo que importa

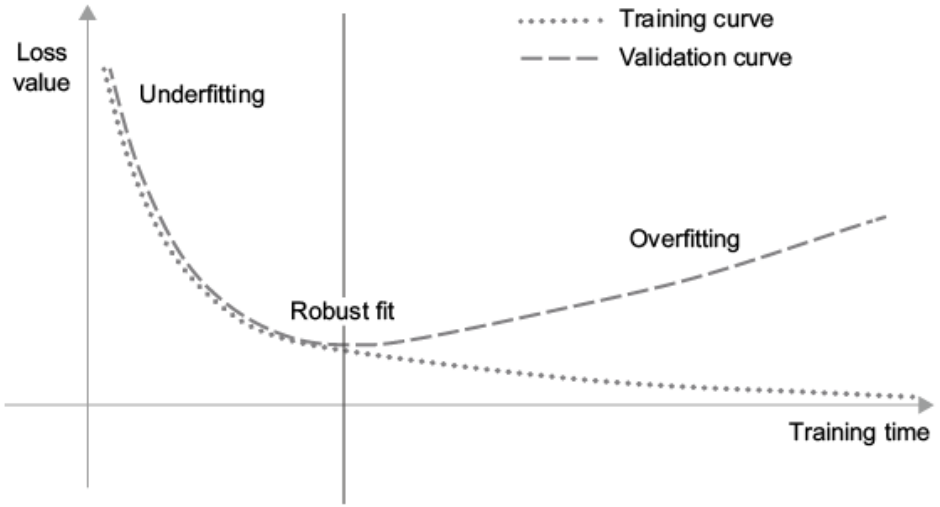

Figure 5.1 Canonical overfitting behavior

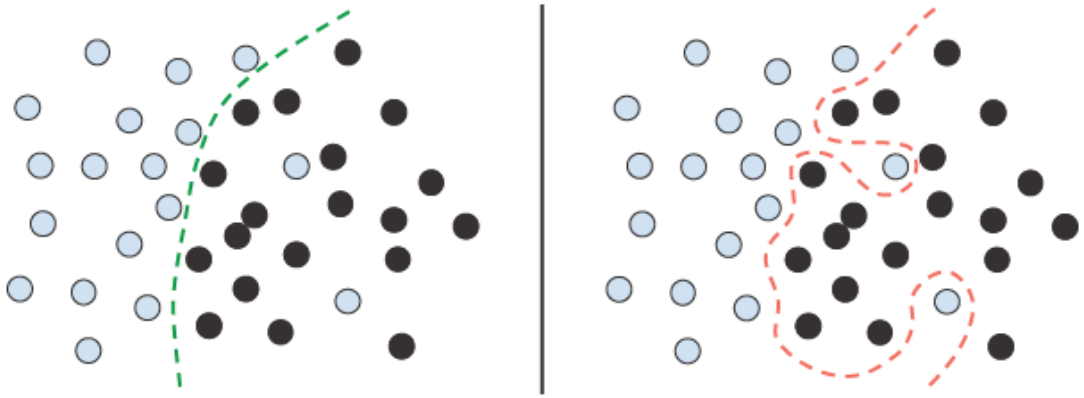

Figure 5.4 Dealing with outliers: robust fit vs. overfitting

La generalización es lo que importa

Figure 5.5 Robust fit vs. overfitting giving an ambiguous area of the feature space

- Características raras o relaciones espurias en los datos.
- Datos representativos.

La hipótesis de la variedad del espacio

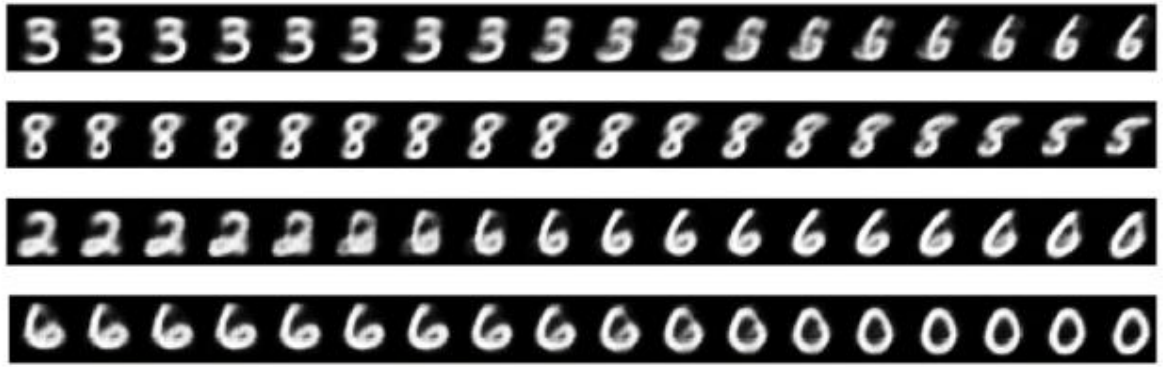

Figure 5.7 Different MNIST digits gradually morphing into one another, showing that the space of handwritten digits forms a "manifold." This image was generated using code from chapter 17.

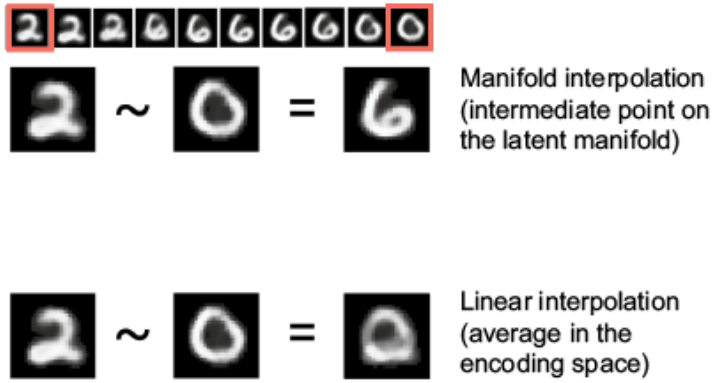

Figure 5.8 Difference between linear interpolation and interpolation on the latent manifold. Every point on the latent manifold of digits is a valid digit, but the average of two digits usually isn't.

La hipótesis de la variedad del espacio

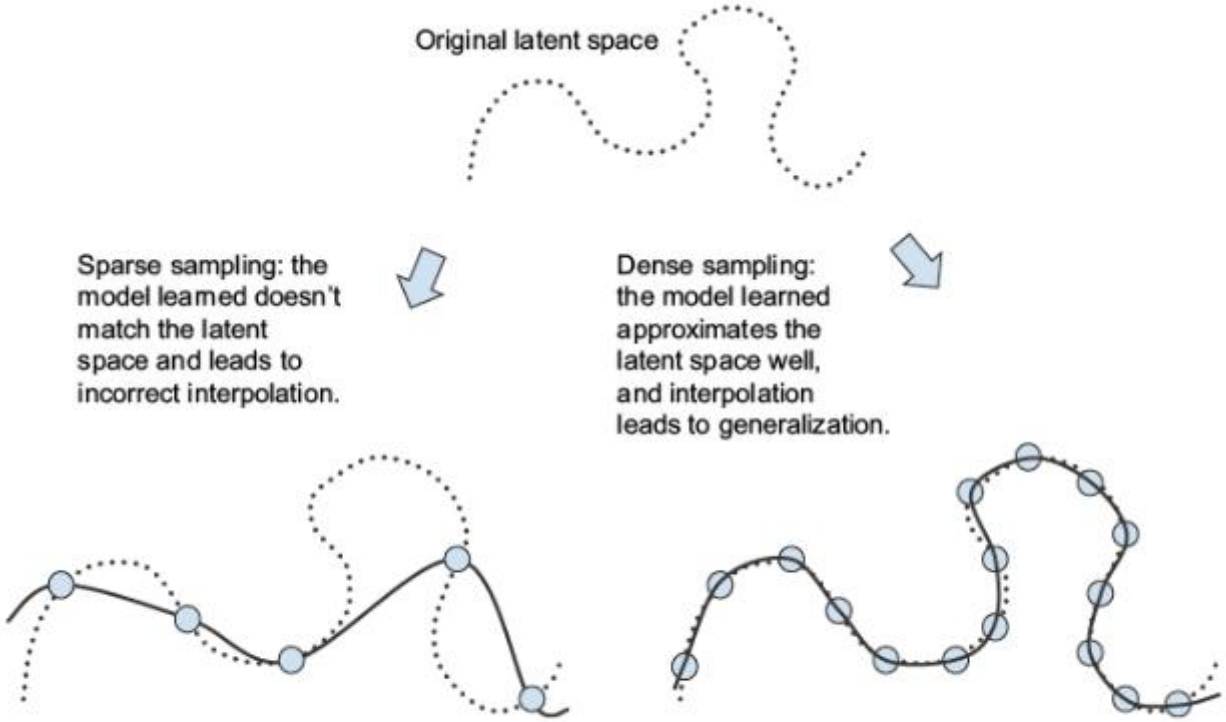

Figure 5.11 A dense sampling of the input space is necessary to learn a model capable of accurate generalization.

Evaluación de los modelos

- Dado que los algoritmos son capaces de sobre ajustarse a los datos, se debe evitar la fuga de información.
- División de los datos en: Entrenamiento, validación y prueba.
- Seleccionar una línea base.
- Validación simple.
- K-conjunto validación

Evaluación de los modelos

Validación simple

Figure 5.12 Simple hold-out validation split

K-conjunto validación

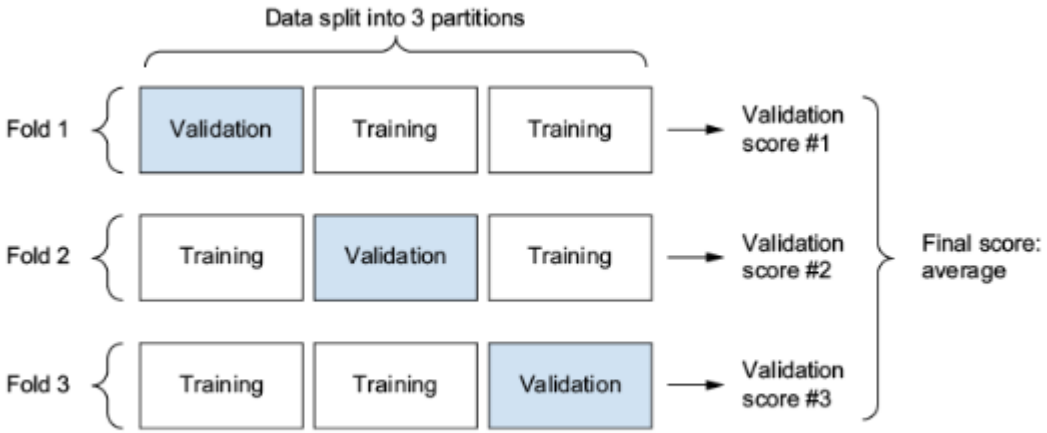

Figure 5.13 Three-fold validation

Evaluación de los modelos

- Representación de los datos.
- La dirección del tiempo.
- Redundancia en los datos.

Mejorar el ajuste

- Presentaciones
- ¿Qué errores tuvieron?
- ¿Qué estamos buscando en nuestro ejercicio?

Mejorar el ajuste (escenarios)

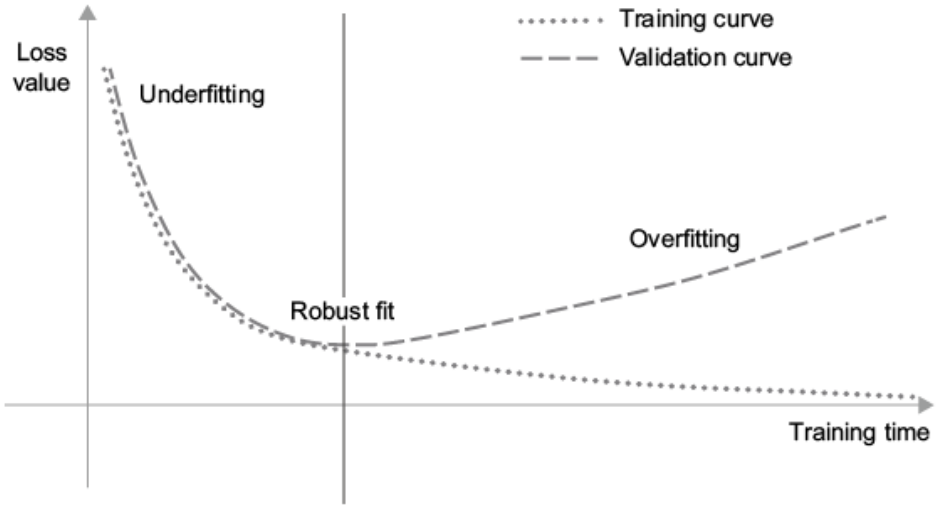

Figure 5.1 Canonical overfitting behavior

- La función de perdida no se reduce con el tiempo.
- Ajustar la tasa de aprendizaje.
- Aumentar el tamaño del lote (batch size).

Mejorar el ajuste (escenarios)

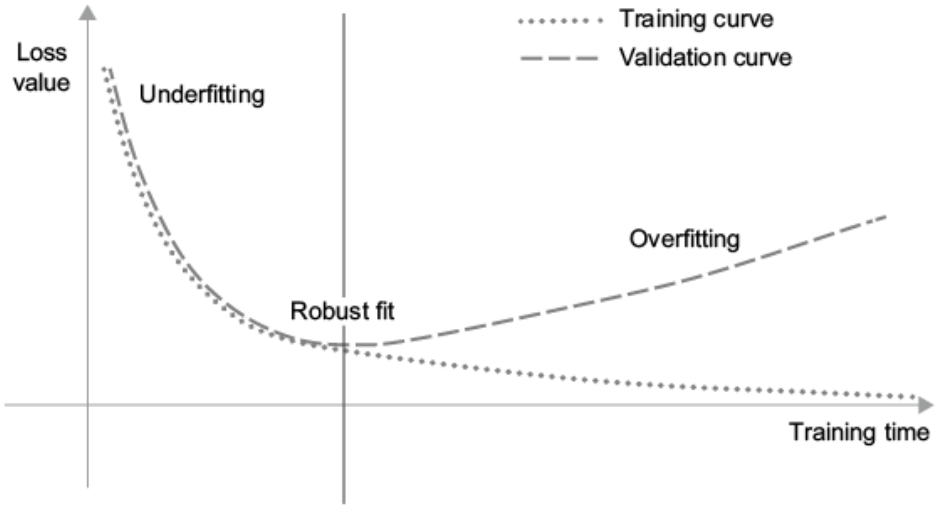

Figure 5.1 Canonical overfitting behavior

- La función de perdida del entrenamiento se reduce con el tiempo, pero no logramos generalizar.
- Es decir la función de perdida de validación no se reduce con el tiempo.
- Los datos no sean representativos.
- Usar arquitecturas que se ajustan a los datos.

Mejorar el ajuste (escenarios)

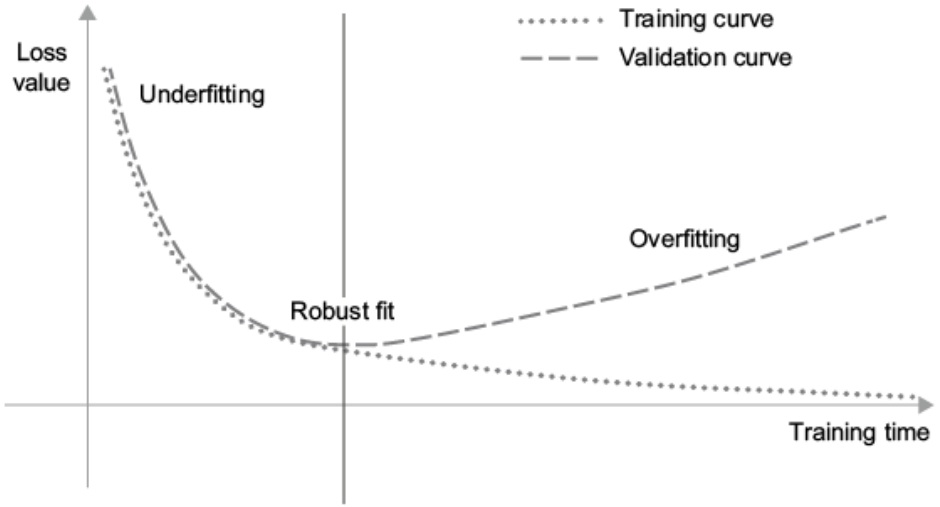

Figure 5.1 Canonical overfitting behavior

- La funciones de perdida (entrenamiento y validación) se reduce con el tiempo, pero no se logra superar la línea base.
- Incrementar el numero de capas y neuronas.

Aspectos claves para generalizar

- Curación de los datos.
- Ingeniería de características.
- Uso parada temprana.
- Regularizar el modelo.

Aspectos claves para generalizar

- Curación de los datos.
  - Tener suficientes datos.
  - Eliminar los errores de etiquetado.
  - Limpiar los datos y gestionar los valores perdidos.
  - Hacer la selección de caracteristicas.

Aspectos claves para generalizar

- Ingeniería de características.

Raw data: pixel grid		
Better features: clock hands' coordinates	{x1: 0.7, y1: 0.7} {x2: 0.5, y2: 0.0}	{x1: 0.0, y2: 1.0} {x2: -0.38, y2: 0.32}
Even better features: angles of clock hands	theta1: 45 theta2: 0	theta1: 90 theta2: 140

Figure 5.17 Feature engineering for reading the time on a clock

- One-hot encoding
- TF-IDF
- Embedding

Aspectos claves para generalizar

- Uso parada temprana.

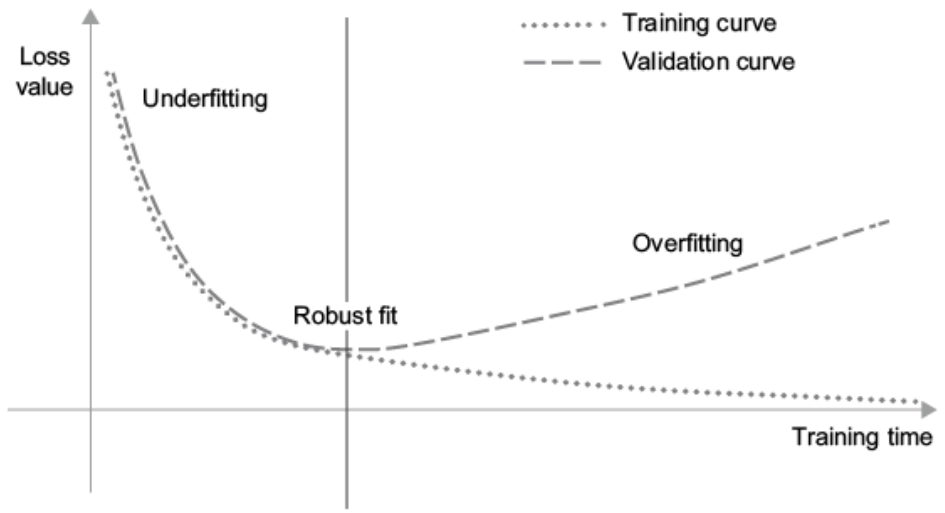

Figure 5.1 Canonical overfitting behavior

De acuerdo con el desempeño de la función de perdida en el conjunto de validación se detiene el entrenamiento

Aspectos claves para generalizar

- Regularizar el modelo.
  - Reducir el tamaño de la red.
  - Agregar regularización de los pesos (L1 – valor absoluto o L2 al cuadrado).
  - Dropout.

Conclusiones

- Generalizar es el objetivo.
- Interpolación de la variedad de los datos.
- Seguir el método de evaluación (simple validación o k-conjunto).
- Primero es sobreajustar el modelo con algo de generalización.
- Segundo con sobreajuste se busca regualizar el modelo para mejorar la generalización.