

# Análisis del flujo de datos del aprendizaje automático

Juan Pajaro

15 abril 2026

# Contenido

- Método general.
- Reuso de datos de HCE.
- Definición de la tarea analítica.
- Evaluación del entrenamiento


# Terminología común entre epidemiología y aprendizaje de máquina

**Table 1** Linking terms and phrases in epidemiology and machine learning

| Term in epidemiology and biostatistics                                                     | Term in machine/statistical learning                    |
|--------------------------------------------------------------------------------------------|---------------------------------------------------------|
| Dependent variable; outcome variable; response variable                                    | Label/class                                             |
| Independent variable; predictor variable; explanatory variable                             | Feature                                                 |
| Contingency table; $2 \times 2$ table                                                      | Confusion matrix                                        |
| Sensitivity                                                                                | Recall                                                  |
| Positive predictive value                                                                  | Precision                                               |
| Deep learning                                                                              | Artificial neural network with more than 1 hidden layer |
| Outcome group with the highest frequency                                                   | Majority class                                          |
| Outcome group with the lowest frequency                                                    | Minority class                                          |
| Proportion of cases in each category of the outcome variable (when outcome is categorical) | Class balance                                           |

# Método

- Definir la tarea. Comprender el problema. Comprender que representan los datos.
- Desarrollar el modelo. Preparar los datos para que sean procesados por un algoritmo de aprendizaje de maquina.
- Desplegar el modelo. Integrar el modelo a un servidor web, una aplicación móvil y demás.



**Figure 1**

The end-to-end supervised machine learning workflow.

Wiemken, T. L., & Kelley, R. R. (2020). Machine Learning in Epidemiology and Health Outcomes Research. *Annual Review of Public Health*, 41(Volume 41, 2020), 21–36. <https://doi.org/10.1146/annurev-publhealth-040119-094437>




Fig. 1. The machine learning lifecycle comprises four stages performed using a spiral process model.

Ashmore, R., Calinescu, R., & Paterson, C. (2021). Assuring the Machine Learning Lifecycle: Desiderata, Methods, and Challenges. *ACM Computing Surveys*, 54(5), 111:1-111:39. <https://doi.org/10.1145/3453444>

# Método

- Selección de características se basa en dominio de conocimiento.
  - Tabular.
  - ¿Cuando son tensores?
  - ¿Cuando es texto?
  - ¿Cuando es imágenes?
  - ¿Cuándo es HCE con multimodales?
- La ingeniería de características son transformaciones estadísticas.

# Retos del reuso de HCE (Electronic health record)

- Fueron diseñados para el cuidado clínico, no la investigación.
- Estas sesgados hacia personas enfermas.
- Demuestran diferencias sustanciales en los diagnósticos entre regiones.
- Es fragmentado entre sistemas de información debido a múltiples visitas a centros de salud. Genera falta de información.
- Son inexactos. Muchas inexactitudes pueden incluirse durante la visita clínica.
- Registrados y almacenados en diferentes formas y unidades.



# Retos del reuso de HCE (Electronic health record)

- Los acrónimos pueden que tengan diferentes significados.
- Valores fisiológicos imposibles.
- Contienen datos que deben ser protegidos.

# Retos del reuso de HCE (Electronic health record)

Los datos de las HCE son:

- No curados (los datos no se seleccionan cuidadosamente ni se organizan o presentan de forma deliberada),
- De baja calidad (los datos rara vez se someten a auditorías de calidad),
- De alta dimensionalidad (miles de eventos médicos distintos),
- Dispersos (gran cantidad de valores en cero), heterogéneos (provenientes de diferentes fuentes),
- Temporales (los datos se recopilan a lo largo del tiempo),
- Incompletos (valores faltantes),
- De gran escala (un gran volumen de datos)
- y multimodales (múltiples modalidades de datos)

# Definición de la tarea analítica

- ¿Qué es una tarea analítica?
- Es identificar la representación de los datos con la representación del algoritmo.

# Definición de la tarea analítica

**Table 1.1** Data Science Tasks and Examples

| Tasks                   | Description                                                                                                                     | Algorithms                                                                                     | Examples                                                                                                                                     |
|-------------------------|---------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------|
| Classification          | Predict if a data point belongs to one of the predefined classes. The prediction will be based on learning from a known dataset | Decision trees, neural networks, Bayesian models, induction rules, <i>k</i> -nearest neighbors | Assigning voters into known buckets by political parties, e.g., soccer moms<br>Bucketing new customers into one of the known customer groups |
| Regression              | Predict the numeric target label of a data point. The prediction will be based on learning from a known dataset                 | Linear regression, logistic regression                                                         | Predicting the unemployment rate for the next year<br>Estimating insurance premium                                                           |
| Anomaly detection       | Predict if a data point is an outlier compared to other data points in the dataset                                              | Distance-based, density-based, LOF                                                             | Detecting fraudulent credit card transactions and network intrusion                                                                          |
| Time series forecasting | Predict the value of the target variable for a future timeframe based on historical values                                      | Exponential smoothing, ARIMA, regression                                                       | Sales forecasting, production forecasting, virtually any growth phenomenon that needs to be extrapolated                                     |
| Clustering              | Identify natural clusters within the dataset based on inherent properties within the dataset                                    | <i>k</i> -Means, density-based clustering (e.g., DBSCAN)                                       | Finding customer segments in a company based on transaction, web, and customer call data                                                     |
| Association analysis    | Identify relationships within an item set based on transaction data                                                             | FP-growth algorithm, a priori algorithm                                                        | Finding cross-selling opportunities for a retailer based on transaction purchase history                                                     |
| Recommendation engines  | Predict the preference of an item for a user                                                                                    | Collaborative filtering, content-based filtering, hybrid recommenders                          | Finding the top recommended movies for a user                                                                                                |

LOF, *local outlier factor*; ARIMA, *autoregressive integrated moving average*; DBSCAN, *density-based spatial clustering of applications with noise*; FP, *frequent pattern*.

# Definición de la tarea analítica

## Part II Biomedical NLP Tasks and Methods

|           |                                                                              |            |
|-----------|------------------------------------------------------------------------------|------------|
| <b>4</b>  | <b>Named Entity Recognition</b> .....                                        | <b>79</b>  |
|           | Murthy V. Devarakonda, Kalpana Raja, and Hua Xu                              |            |
| <b>5</b>  | <b>Relation Extraction</b> .....                                             | <b>101</b> |
|           | Murthy V. Devarakonda, Kalpana Raja, and Hua Xu                              |            |
| <b>6</b>  | <b>Medical Concept Normalization</b> .....                                   | <b>137</b> |
|           | Hua Xu, Dina Demner Fushman, Na Hong, and Kalpana Raja                       |            |
| <b>7</b>  | <b>Text Classification</b> .....                                             | <b>165</b> |
|           | Trevor Cohen, Serguei Pakhomov, Amandalynne Paullada,<br>and Meliha Yetisgen |            |
| <b>8</b>  | <b>Information Retrieval</b> .....                                           | <b>195</b> |
|           | Kirk Roberts                                                                 |            |
| <b>9</b>  | <b>Question Answering</b> .....                                              | <b>231</b> |
|           | Dina Demner Fushman                                                          |            |
| <b>10</b> | <b>Large Language Model and Text Generation</b> .....                        | <b>265</b> |
|           | Yonghui Wu                                                                   |            |

# Definición de la tarea analítica

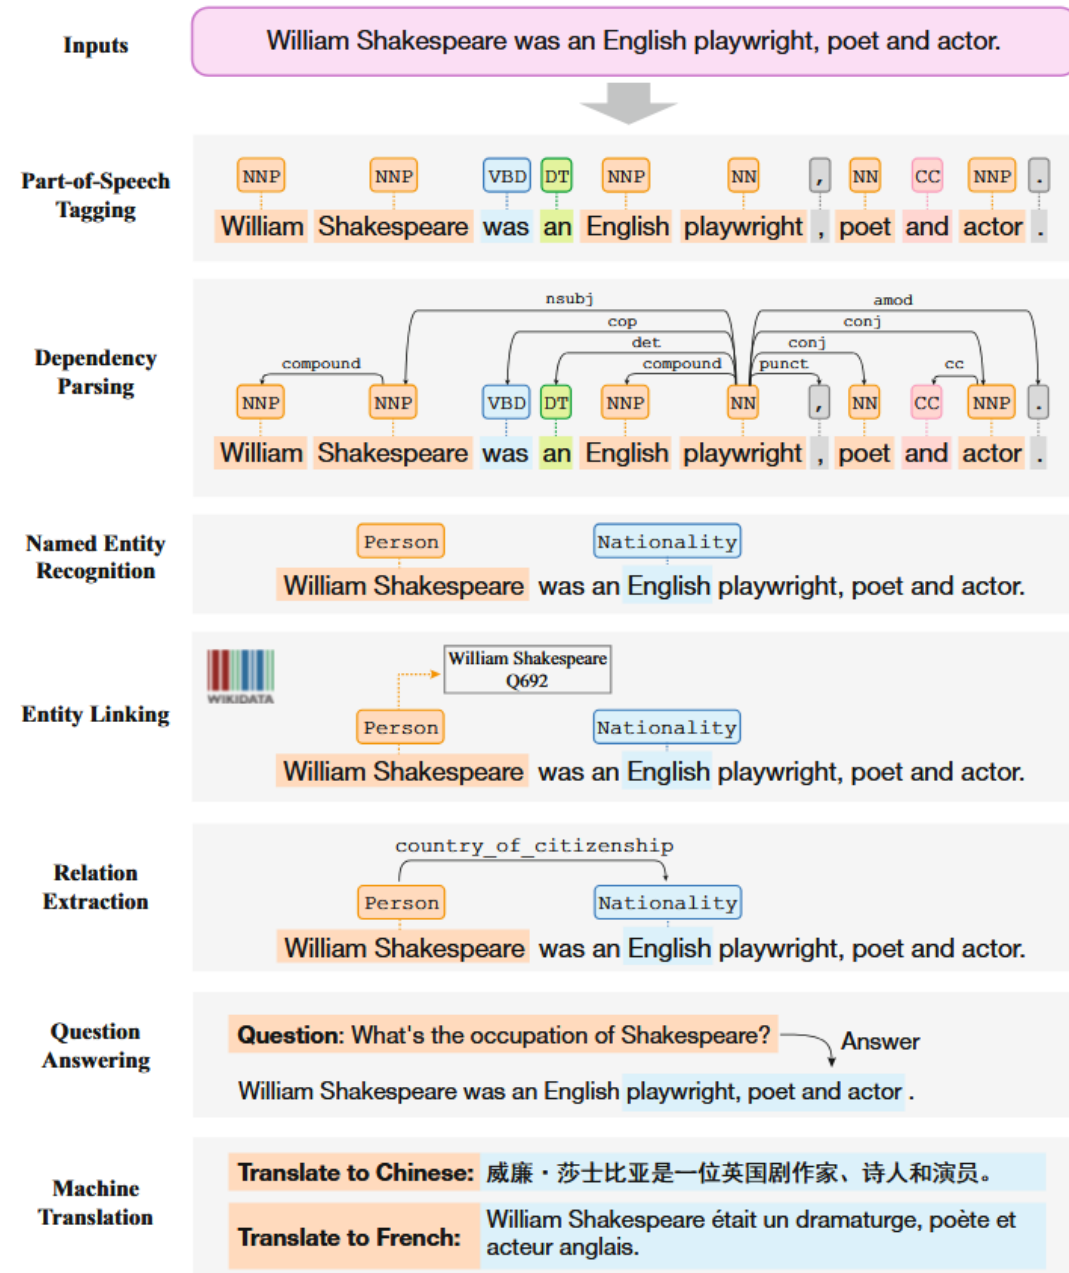


Fig. 1.5 There are various NLP tasks given the same sentence input, such as part-of-speech tagging, dependency parsing, named entity recognition, entity linking, relation extraction, question answering, and machine translation

# Definición de la tarea analítica

- Clasificación de imágenes (médicas).
- Segmentación de imágenes.
- Detección del objeto.

# Definición de la tarea analítica

- Describir el fenómeno.
- Predecir un resultado.
- Encontrar las causas para intervenir y mejorar el resultado.




# Predicción

- Mejorar la exactitud de la predicción.
- Encontrar los predictores óptimos para el resultado.
- Predecir resultados raros.
- Identificación y evaluación de nuevos factores de riesgo.
- Identificación de desviaciones de un proceso normal.

# Evaluación del entrenamiento (Método)

- Antes de pasar al conjunto de prueba, se evalúa el desempeño del modelo entre el conjunto de entrenamiento y el conjunto de validación:
  - La función de pérdida no se reduce con el tiempo.
  - La función de pérdida del entrenamiento se reduce con el tiempo, pero la función de pérdida de validación no se reduce con el tiempo.
  - Las funciones de pérdida (entrenamiento y validación) se reducen con el tiempo, pero no se logra superar la línea base.

# Evaluación del entrenamiento (Método)



**Fig. 2. ML methods for prediction most relevant in the social and health sciences with nontechnical description ranked by interpretability/explainability versus complexity.** Note that classes of methods are represented as larger circles; specific ML methods are represented as small circles within. Ordering and selection of ML methods based on theoretical considerations and experience. ANN, artificial neural network. Copyright by Matthias Klee.